香港月度用电预测项目对外说明报告

1. 报告目的

这份报告不是写给项目开发者看的，而是写给第一次接触这个项目的外部读者看的。

它的目标是用尽量简单、完整、可追溯的方式说明四件事：

- 这个项目到底要解决什么问题
- 项目为什么从周度/小时级预测改成了月度预测
- 项目实际使用了哪些数据集，每个数据集包含什么内容
- 这些数据最终是怎样被组合成一个可以训练模型的数据集，并产出预测结果的

2. 项目一句话概括

这个项目使用香港官方公开数据，建立了一套“从原始数据收集、到月度特征构建、再到用电量预测和结果分析”的完整流程，用来预测香港下一个月的总用电量。

3. 最开始的想法，和为什么后来改了

项目最开始的设想是预测香港每周甚至每小时的用电曲线。

这个想法在方向上是合理的，因为城市用电确实会受到天气、客流、季节、建筑结构和人口活动的影响。

但是在真正收集香港公开数据之后，我们发现一个关键问题：

- 公开数据里，最稳定、最完整的目标数据是“月度总用电量”
- 而不是“全港小时级负荷曲线”

同时，很多解释变量本身也更适合月度任务，例如：

- 月度交通客流
- 月度公共运输统计
- 月度能源统计
- 年度人口预测
- 静态建筑 footprint

所以项目最终做了一个重要调整：

- 原设想：预测每周或每小时的负荷曲线
- 最终实现：预测香港下一个月的总用电量

这个调整让“目标数据”和“解释变量”在时间粒度上统一起来，也让整个项目更加严谨、可复现、适合课程展示。

4. 项目最终回答的问题是什么

项目现在回答的问题是：

- 如果我们已经知道香港这个月以前的用电情况

? 同时也知道天气、节假日、人口活动、交通和城市结构等信息
? 那么我们能不能预测香港下一个月的总用电量

换句话说，这不是一个纯时间序列项目，也不是一个纯城市统计项目，而是一个“把历史用电和外部城市特征结合起来做预测”的项目。

5. 项目数据结构总览

整个项目的数据分成四层。

5.1 raw 层

`raw` 层保存的是从官方来源直接下载下来的原始文件。

这层的作用是：

? 保留最原始的数据
? 方便以后重新清洗
? 避免因为清洗错误而丢失原始来源
? 让项目可追溯

5.2 silver 层

`silver` 层保存的是清洗后的中间数据表。

这层的特点是：

? 列名统一
? 日期格式统一
? 每个表只保留建模真正需要的字段
? 日线数据被汇总成月线
? 年线数据被整理为适合月度建模的形式

5.3 model 层

`model` 层保存的是模型训练直接使用的表。

最核心的文件是：

? `city_monthly_train_ready.csv`

这张表的含义是：

? 每一行代表一个月份
? 每一列代表这个月份已经可以观察到的一个特征
? 目标列代表“下一个月的总用电量”

5.4 result 层

`result` 层保存的是最终给人阅读和展示的内容。

包括：

? 数据分析结果
? 模型评估结果
? 图表
? 错误处理说明
? 报告和展示稿

6. 详细数据集说明

下面按项目真正使用的数据表，逐个说明它们的来源、内容、时间范围、主要字段和作用。

6.1 weather_monthly.csv

文件定位

? 文件名：`data/silver/weather_monthly.csv`
? 行数：1622
? 列数：12
? 时间范围：1884-01 到 2026-02

数据来源

? 香港天文台 HKO 的日度天气历史数据

原始日度表包括：

? 日平均温度
? 日最高温度
? 日最低温度
? 日平均相对湿度
? 日降雨量

进入模型前的处理方式

项目把日度天气先整理成月度天气，再形成一个月一行的表。

主要字段

? `period_month`：月份
? `temp_mean_c_avg`：该月日平均温度的平均值
? `temp_max_c_avg`：该月日最高温度的平均值
? `temp_max_c_peak`：该月出现过的最高温度
? `temp_min_c_avg`：该月日最低温度的平均值
? `temp_min_c_low`：该月出现过的最低温度
? `temp_range_c_avg`：该月平均日温差
? `rh_mean_pct_avg`：该月平均相对湿度
? `rainfall_mm_sum`：该月总降雨量
? `rainfall_day_count`：该月下雨天数

? `hot_day_count`：该月炎热天数
? `cool_day_count`：该月较凉天数

它的作用

天气是解释用电波动最重要的变量之一。

例如：

? 天气更热时，空调负荷通常更高
? 天气更潮湿时，建筑耗能模式可能改变
? 降雨和温差变化也会影响商业和居民活动

6.2 calendar_monthly.csv

文件定位

? 文件名：`data/silver/calendar_monthly.csv`
? 行数：1716
? 列数：5
? 时间范围：1884-01 到 2026-12

数据来源

? 香港政府公开节假日数据
? 同时结合日历规则生成周末和工作日统计

主要字段

? `period_month`：月份
? `days_in_month`：该月总天数
? `weekend_days`：该月周末天数
? `public_holiday_days`：该月公众假期天数
? `business_days`：该月工作日天数

它的作用

日历变量可以解释“同样的天气下，为什么某些月份的用电结构还是不一样”。

例如：

? 节假日多的月份，商业和通勤活动可能下降
? 工作日更多的月份，办公楼和交通相关活动更强

6.3 immigration_city_monthly.csv

文件定位

? 文件名：`data/silver/immigration_city_monthly.csv`

? 行数：63
? 列数：11
? 时间范围：2021-01 到 2026-03

数据来源

? 香港入境事务处的日度旅客流量数据

原始数据按口岸和方向记录。

项目在清洗时把它汇总成城市层面的月度总量。

主要字段

? `period_month`：月份
? `immigration_arrival_hk_residents`：香港居民入境人数
? `immigration_departure_hk_residents`：香港居民离境人数
? `immigration_arrival_mainland_visitors`：内地访客入境人数
? `immigration_departure_mainland_visitors`：内地访客离境人数
? `immigration_arrival_other_visitors`：其他访客入境人数
? `immigration_departure_other_visitors`：其他访客离境人数
? `immigration_arrival_total_passengers`：总入境人数
? `immigration_departure_total_passengers`：总离境人数
? `immigration_total_cross_border_passengers`：总跨境旅客量
? `immigration_net_arrivals_total_passengers`：净流入旅客量

它的作用

这组数据是“城市活动强度”的代理变量。

如果一个月旅客和跨境人流更多，通常意味着：

? 商业活动更活跃
? 交通活动更密集
? 零售、办公、服务类负荷更强

6.4 transport_public_total_monthly.csv

文件定位

? 文件名：`data/silver/transport_public_total_monthly.csv`
? 行数：157
? 列数：2
? 时间范围：2013-01 到 2026-01

数据来源

? 香港运输署月度交通与运输摘要

主要字段

? `period_month`：月份
? `public_transport_total_avg_daily_pax`：该月平均每日公共交通总客运量

它的作用

这是另一个反映“城市整体活跃程度”的核心变量。

它比单一模式更概括，可以快速表示：

? 这个月整体通勤是否更强
? 城市活动强度是否上升

6.5 transport_public_mode_wide_monthly.csv

文件定位

? 文件名：`data/silver/transport_public_mode_wide_monthly.csv`
? 行数：157
? 列数：8
? 时间范围：2013-01 到 2026-01

数据来源

? 香港运输署月度公共交通客运量表

主要字段

? `period_month`
? `public_transport_ferries_avg_daily_pax`
? `public_transport_fran_bus_avg_daily_pax`
? `public_transport_lrb_avg_daily_pax`
? `public_transport_plb_avg_daily_pax`
? `public_transport_rs_avg_daily_pax`
? `public_transport_railways_avg_daily_pax`
? `public_transport_tax_avg_daily_pax`

它的作用

相比总量表，这张表更细，能让模型区分不同交通模式的变化。

例如：

? 铁路流量更能反映核心通勤
? 渡轮与特定区域活动相关
? 巴士和小巴更能反映地面交通结构

6.6 transport_cross_harbour_monthly.csv

文件定位

? 文件名：`data/silver/transport_cross_harbour_monthly.csv`
? 行数：157
? 列数：4
? 时间范围：2013-01 到 2026-01

数据来源

? 香港运输署的过海交通月度统计

主要字段

? `period_month`
? `cross_harbour_av_pax`
? `cross_harbour_db_pax`
? `cross_harbour_total_pax`

它的作用

过海交通是香港非常有代表性的城市活动指标。

它能帮助模型识别：

? 港岛与九龙、新界之间的活动强度变化
? 通勤和跨区出行的变化

6.7 city_energy_monthly.csv

文件定位

? 文件名：`data/silver/city_energy_monthly.csv`
? 行数：566
? 列数：8
? 时间范围：1979-01 到 2026-02

数据来源

? 香港政府统计处 C&SD 月度能源统计

这是整个项目最关键的数据表之一，因为它里面包含了真正要预测的目标。

主要字段

? `period_month`
? `electricity_commercial_tj`：商业用电量
? `electricity_domestic_tj`：住宅用电量
? `electricity_industrial_tj`：工业用电量
? `electricity_street_lighting_tj`：街灯用电量
? `electricity_total_tj`：总用电量

? `gas_total_tj`：总燃气用量
? `electricity_export_to_mainland_tj`：输往内地电量

它的作用

这张表同时承担两个角色：

第一，它提供项目的预测目标：

? `electricity_total_tj`

第二，它也提供额外解释信息：

? 商业、住宅、工业、街灯等分项用电量
? 燃气总量作为能源活动背景变量

6.8 hkelectric_re_generation_monthly.csv

文件定位

? 文件名：`data/silver/hkelectric_re_generation_monthly.csv`
? 行数：61
? 列数：4
? 时间范围：2021-01 到 2026-01

数据来源

? 港灯发布的月度可再生能源发电量数据

主要字段

? `period_month`
? `hkelectric_re_generation_solar_photovoltaic`
? `hkelectric_re_generation_wind_power`
? `hkelectric_re_generation_grand_total`

它的作用

这张表不是用来直接代表总负荷，而是用来补充能源结构背景。

它可以帮助模型理解：

? 某些月份能源系统背景是否发生变化
? 可再生发电是否反映了季节性条件变化

6.9 city_population_yearly.csv

文件定位

? 文件名：`data/silver/city_population_yearly.csv`
? 行数：11

? 列数：4
? 时间范围：2019 到 2029

数据来源

? 香港人口预测相关公开空间数据

主要字段

? `year`
? `population`
? `district_area_m2`
? `population_density_per_km2`

它的作用

这是一组“慢变化”的城市结构变量。

它们不是每天都变，但决定了香港整体的负荷底盘：

? 人口越多，整体生活和商业活动基础越大
? 人口密度越高，空间利用和建筑运行结构也会不同

6.10 ev_city_static.csv

文件定位

? 文件名：`data/silver/ev_city_static.csv`
? 行数：1
? 列数：7
? 类型：静态表

数据来源

? 香港公共电动车充电设施公开数据

主要字段

? `ev_standard_chargers`
? `ev_medium_iec62196_chargers`
? `ev_quick_chademo_chargers`
? `ev_quick_ccs_combo_chargers`
? `ev_quick_iec62196_chargers`
? `ev_quick_gbt_dc_chargers`
? `ev_total_chargers`

它的作用

这组数据代表香港当前电动车充电基础设施规模。

虽然它不是月度动态变化数据，但它提供了一个重要的城市结构背景：

? 电力使用方式正在变化
? 充电网络规模可以反映电力需求结构升级趋势

6.11 building_footprints_city_static.csv

文件定位

? 文件名：`data/silver/building_footprints_city_static.csv`
? 行数：1
? 列数：6
? 类型：静态表

数据来源

? 香港建筑 footprint 空间数据

主要字段

? `building_count`
? `building_block_type_count`
? `footprint_area_m2_sum`
? `footprint_area_m2_mean`
? `building_height_m_mean`
? `completed_building_count`

它的作用

这是一组描述香港整体建筑存量结构的静态变量。

它代表的是城市电力需求的空间和物理基础：

? 建筑数量
? 建筑占地面积
? 平均建筑高度
? 已建成建筑规模

这些变量不会解释短期波动，但它们能解释“为什么香港的负荷底盘是现在这个规模”。

7. 模型训练前，数据是怎样被统一到一起的

上面这些表来自不同部门、不同格式、不同时间粒度。

如果直接拿来训练，是不能用的。

所以项目做了统一处理。

7.1 时间统一

? 日线数据先按月汇总
? 月线数据直接保留
? 年线数据按年份对齐到每个月
? 静态数据复制到所有月份

7.2 字段统一

不同来源的数据字段名称完全不一样。

所以项目把字段重新命名成统一风格，例如：

? 所有月度时间字段统一为 `period_month`
? 温度和交通字段都改成有意义、可解释的英文名

7.3 目标列构造

模型最终要预测的是：

? `target_electricity_total_t_plus_1m`

它表示：

? 对于当前月份 t
? 目标不是这个月自己的总用电量
? 而是下一个月 `t+1` 的总用电量

这样才是真正的预测任务，而不是事后拟合。

7.4 历史特征构造

项目给模型加入了一组历史用电特征，包括：

? `electricity_lag_1m`
? `electricity_lag_2m`
? `electricity_lag_3m`
? `electricity_lag_6m`
? `electricity_lag_12m`
? 3、6、12 个月滚动均值
? 同比变化

这些特征很重要，因为用电序列本身存在强烈的季节性和惯性。

8. 最终训练数据集长什么样

模型最终使用的是：

? `data/model/city_monthly_train_ready.csv`

它的规模是：

? 157 行
? 89 列

? 时间范围：2013-01 到 2026-01

为什么从 2013 年开始？

因为：

? 公共交通月度数据从 2013 年起比较完整
? 从这个时间点开始，主要外生变量的覆盖更稳定

也就是说，虽然某些原始表更早就有数据，但为了保证训练表质量，项目选择了“交集更稳定”的时间窗口。

9. 数据处理时遇到的主要问题

项目不是把表简单拼起来就结束了，而是在数据工程阶段解决了一些非常现实的问题。

9.1 不同数据源的时间粒度不同

问题：

? 有的数据是日线
? 有的是月线
? 有的是年线

处理：

? 全部对齐到月度任务

9.2 不同数据源的时间起点不同

问题：

? 用电目标数据很早就有
? 但客流、交通、人口、可再生发电的起点较晚

处理：

? 使用可用性标记
? 并选择 2013 年以后作为主训练窗口

9.3 文件格式与后缀不一致

问题：

? 港灯有一份文件文件名像 CSV
? 但实际内容是 Excel 工作簿

处理：

? 在读取前先检查文件签名，再选择正确读取方式

9.4 统计表 period 字段混合了不同时间单位

问题：

? 同一个统计系统中，period 可能表示年、季度或月

处理：

- 显式解析 period
- 仅保留合法月度记录作为月度目标表

9.5 年度人口数据无法直接按月使用

问题：

- 人口预测是年度表
- 但模型是月度任务

处理：

- 先按年份映射到每个月
- 如果月份超出可用区间，则裁剪到最近可用年份

10. 模型部分是怎么做的

项目没有一开始就追求最复杂的模型，而是先搭建了几组能清楚解释结果的 baseline。

10.1 主模型 baseline

一共训练了三种主模型：

- Seasonal naive
- Ridge regression
- Random Forest

其中：

- Seasonal naive 的意思是“直接用去年同一个月作为预测”
- Ridge 是带正则化的线性模型
- Random Forest 是非线性树模型

10.2 解释性回归模型

为了让外部读者更容易理解“哪些变量有帮助”，项目又补做了两组线性回归：

- Simple linear regression
- Multiple linear regression

前者只使用一个最强季节性变量：

- `electricity_lag_12m`

后者使用一组更完整的解释变量，包括：

- 历史用电
- 天气
- 节假日
- 客流
- 交通

? 燃气
? 季节编码

11. 结果是什么

11.1 主模型 baseline 结果

? Seasonal naive：MAE 1210.57，RMSE 1396.17，R2 0.7054
? Ridge：MAE 928.35，RMSE 1375.55，R2 0.7141
? Random Forest：MAE 456.93，RMSE 609.79，R2 0.9438

这说明：

? 去年同月这个简单规则已经能抓到一部分规律
? 线性模型有一定提升
? Random Forest 表现最好，说明当前任务存在明显的非线性关系

11.2 回归验证结果

? Simple regression：MAE 1155.41，RMSE 1346.22，R2 0.7261
? Multiple regression：MAE 784.25，RMSE 944.58，R2 0.8652

这说明：

? 只看历史季节性已经能做出一个还不错的预测
? 但把天气、节假日、客流、交通和燃气等变量加进去以后，效果明显更好

12. 这些指标该怎么理解

为了方便非技术读者理解，这里简单解释三个最常见的指标。

MAE

MAE 表示平均绝对误差。

它可以理解成：

? 模型平均每个月会错多少

数值越小越好。

RMSE

RMSE 也表示误差，但会对大误差惩罚更重。

如果一个模型 RMSE 很大，通常说明它在某些月份会出现明显偏差。

R2

R2 可以理解成模型对目标变化的解释程度。

它越接近 1，说明模型越能解释数据里的波动规律。

13. 结果告诉了我们什么

这个项目最重要的结论有四点。

第一，香港月度总用电量是可以预测的。

第二，历史用电确实很重要，因为季节性非常明显。

第三，仅靠历史用电还不够，天气、节假日、客流和交通等动态变量提供了额外信息。

第四，从公开数据现实条件来看，月度任务比最初设想的小时级任务更可靠，也更适合教学项目。

14. 项目的边界和限制

这份报告也需要坦诚说明项目当前的边界。

14.1 这是“香港整体月度预测”，不是分区预测

因为当前最稳定的公开目标数据是香港整体月度总量，而不是分区月度负荷。

14.2 这是“总量预测”，不是小时负荷曲线预测

因为公开数据没有提供稳定、持续的全港小时级目标标签。

14.3 部分结构特征是静态或慢变化的

例如：

- EV charger
- 建筑 footprint
- 年度人口

这些变量更适合解释长期底盘，而不一定能解释每个月的短期波动。

15. 项目已经交付了什么

到现在为止，这个项目已经形成了一个完整的、可运行的交付物。

包括：

- 自动数据收集流程
- 月度清洗后的 silver 数据层
- train-ready 训练数据集
- baseline 训练和评估代码
- 解释性回归验证
- 错误处理说明
- 图表结果包
- 外部读者可读的报告

16. 如果未来继续做，可以怎么扩展

如果后续要继续做，可以考虑三个方向。

第一，加入更多经济活动数据，例如旅游、消费、就业和商业景气指标。

第二，尝试更多模型，例如 XGBoost、LightGBM 或专门的时间序列模型。

第三，如果未来能拿到更细粒度的官方或合作数据，再把项目扩展回周度甚至小时级预测。

17. 最后总结

这不是一个只停留在概念层面的项目。

它已经完成了：

- ? 数据源识别
- ? 原始数据采集
- ? 月度特征工程
- ? 训练表构造
- ? 模型训练
- ? 结果评估
- ? 报告输出

因此，这个项目可以被看成一套完整的“香港月度用电预测”工作流，而不是单一的一份代码或图表。

? 1????????????

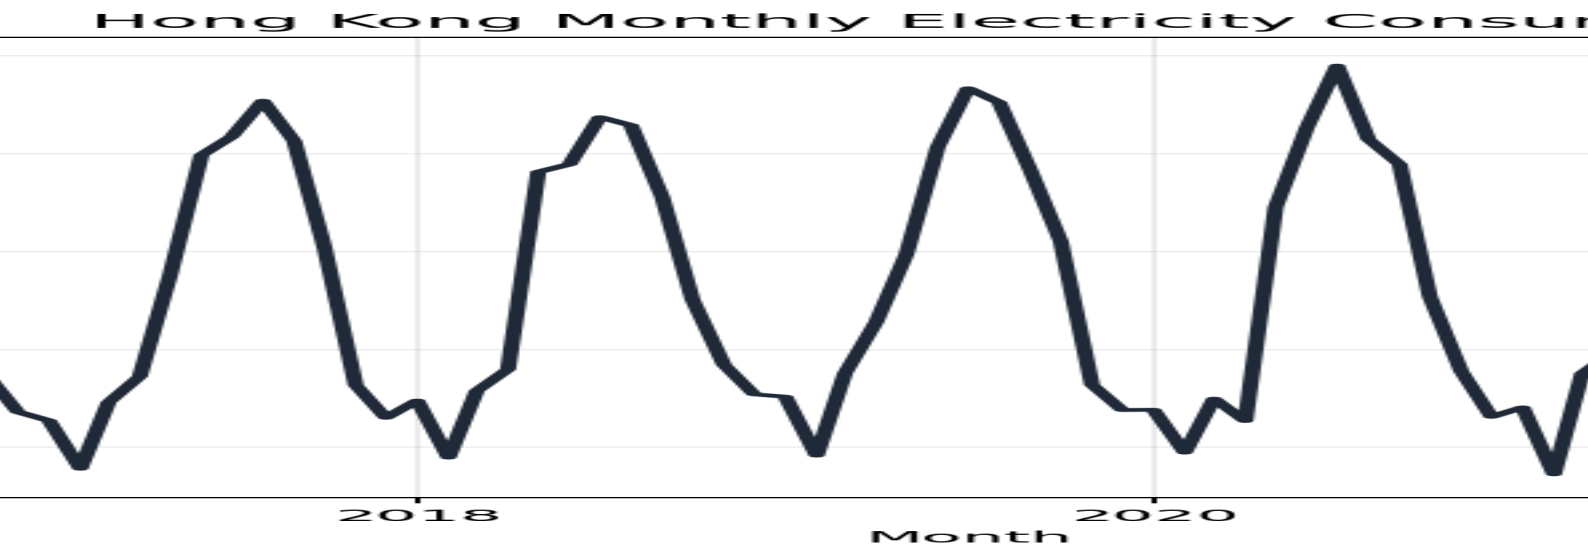

? 1????????????

? 2?????????????

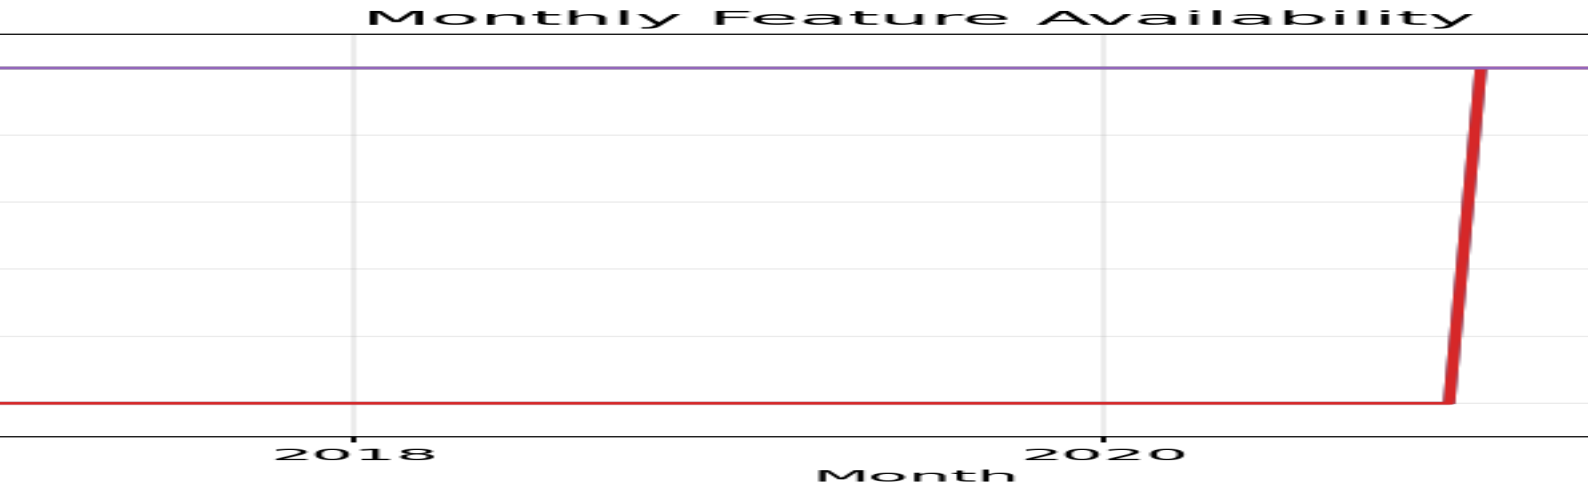

? 2?????????????

? 3???? baseline ????

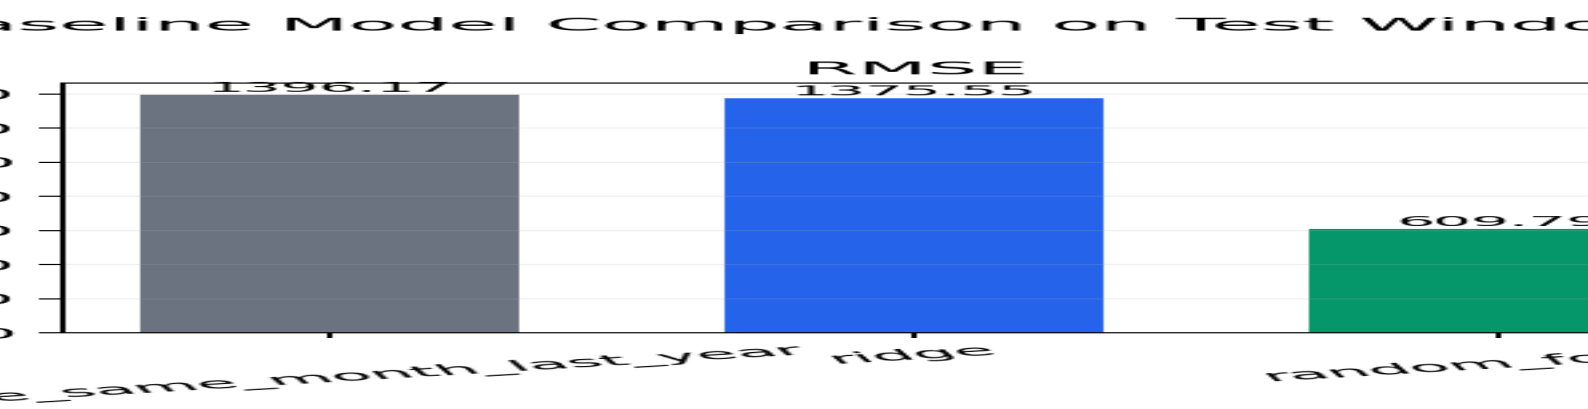

? 3???? baseline ????

? 4?????????????????

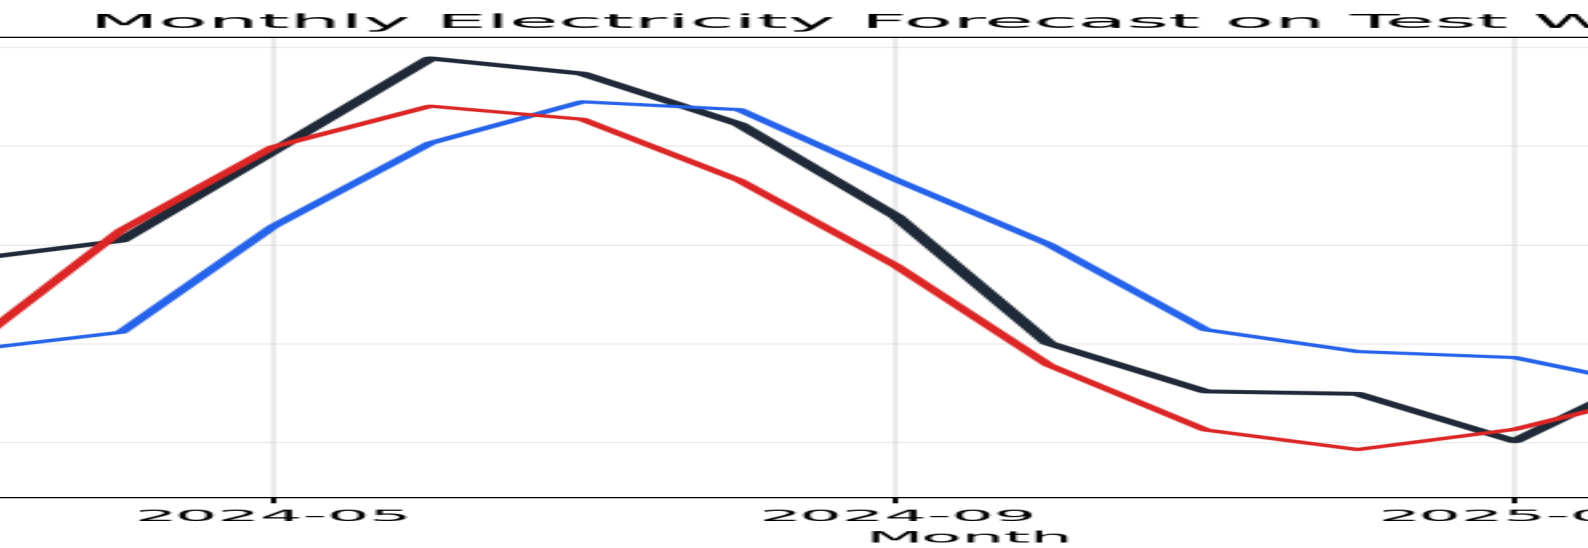
Monthly Electricity Forecast on Test W
2024-05
2024-09
2025-0
Month

? 4?????????????????