ChatGPT

用于预测香港整体与分区每周用电负荷曲线的数据集设计方案

执行摘要

本报告提出一个“关系型（维表/元数据）+ 时序型（高频事实表）”的混合数据集架构，用于预测香港**整体**与**分区**（假定分区为：九龙、港岛、新界；如需不同分区口径则标注为“未指定”）的**每周用电负荷曲线**：以**小时**为基础时间分辨率（形成每周 168 点的负荷曲线），同时支持按日/周聚合评估。核心设计思想是：
1）负荷预测问题的“决定性信息”来自**历史负荷形态 + 天气 + 日历效应**；因此 P0 优先建设“主负荷时序表 + 天气表 + 节假日表”。[1]
2）为实现“整体/分区”的宏观预测，需要清晰的**时区对齐规则**与**空间映射**（测站→分区、建筑/设施→分区）。香港天文台开放数据接口明确采用带时区的时间戳格式（示例带 “+08:00”），可作为统一对齐基准。[2]
3）“分区负荷”的公开高频（小时级）真实负荷数据并不总是可公开获取，因此设计中将负荷数据源抽象为多种模式：电力公司/智能电表导出、校园/园区智能表数据库（如 HKUST 数据集）、以及业务合作数据；并通过元数据与质量表记录来源与可用性，便于在课程项目中先用公开数据搭起可复现管道，再逐步替换为更贴近城市层面的真实负荷。[3]
4）对课程项目，建议先落地“简化基线数据集版本”：以 HKUST 校园智能电表公开数据作为主负荷时序，叠加香港天文台天气与节假日，再加入低频城市活动代理（如入境处每日客流、运输署交通探测器数据）作为扩展特征；并给出将单栋/建筑群耗电聚合到“区域负荷”的评估方法。[4]
5）在维护层面，建议采用增量更新（append-only）与数据版本控制（数据快照/Parquet 分区+元数据登记），并以隐私合规（PDPO）为边界：任何可回溯到个体/住户的细粒度用电都应进行最小化、去标识化与访问控制。[5]

项目目标与预测粒度

目标定义

目标（假定）：预测香港**整体**与分区（示例：九龙、港岛、新界）在未来一周的**用电负荷曲线**（每周 168 个小时点）。若用户需要更细/更粗粒度（如 15 分钟、日峰值、或按 18 区/街区/楼宇），则属于“未指定”，可在路线图中扩展。

预测对象（label）建议：
- `load_value`：小时级负荷量（推荐使用功率需求 MW 或 kW；若数据源是智能电表能量，则用小时电量 kWh 并在表中标注度量类型）。
- `zone_id`：分区标识（HK_TOTAL / KOWLOON / HK_ISLAND / NEW_TERRITORIES）。分区口径可与用电公司服务区对齐：中电（CLP Power Hong Kong）[6] 公开数据页按“九龙/新界”给出区域维度，存在天然映射；而香港电灯（HK Electric）[7] 公开数据按港岛相关区（如中西区、东区、湾仔、南区、离岛（仅南丫岛））等提供统计。[8]

时间粒度与聚合口径

- **基础时间分辨率（假定）**：小时（`1h`）。
- **周聚合**：每周 168 点曲线；同时支持把预测结果汇总到“周总电量/周峰值/周负荷因子”等指标。

- **周定义**：以香港本地时区（HKT, UTC+8）定义周边界：建议采用 ISO 周（周一 00:00:00 至周日 23:00:00）。香港天文台 API 时间戳示例含 “+08:00”，便于统一以 HKT 进行周对齐。 [2]

假设与未指定项清单

- 已假定“分区=九龙/港岛/新界”；若要按 18 区或按电力公司供电区更细拆分，属于“未指定”，但模型与数据结构可平滑扩展。 [8]
- 预测步长与预测范围：假定做“周前瞻（week-ahead）”逐小时预测；若要做“次日/小时 ahead”，属于“未指定”，但只需调整 label 对齐与特征窗口。
- 负荷数据可得性：城市级小时负荷未承诺“公开可得”；因此本报告把“负荷”作为可插拔数据源，并提供课程基线的公开替代（HKUST 校园级）。 [9]

候选特征与数据源

本节按“动态/静态”列出**全部候选特征**（以课程可执行为导向，覆盖从 P0 到 P2 的扩展），并为每项给出：数据类型、频率、优先官方/原始数据源、获取方法、质量风险与缺失处理建议、示例字段名与单位。

动态特征候选（随时间变化）

> 说明：对于由模型内部生成的“滞后/滚动”特征，本报告将其视为动态特征，但数据源标为“由主时序表派生”，获取方法为“ETL/特征工程生成”。

动态特征	数据类型	频率	可能数据源（优先官方/原始）	获取方法	质量风险与缺失处理建议	示例字段名（单位）
小时负荷（目标/历史）	FLOAT	小时	电力公司/智能电表导出；商业客户可下载半小时负荷曲线的服务侧证据存在；住宅智能电表可查看小时用电的服务侧证据存在	账户导出/合作数据/本地采集归档；（课程替代）公开校园智能表数据	计量口径差异（kWh vs kW/MW）；时钟漂移；缺测需用插值/同周同小时回填；异常可用 Hampel/分位数剪裁	`load_value`（kWh 或 kW/MW），`measure_type`（ENUM） [10]
滞后负荷特征（lag）	FLOAT	小时	主时序负荷表派生	特征工程（SQL/Pandas）	需要防止数据泄漏（预测时仅用 t 之前）；缺失用更短滞后或同周模式回填	`load_lag_1h`（同单位）、`load_lag_24h`、`load_lag_168h`
负荷滚动统计（rolling）	FLOAT	小时	主时序负荷表派生	特征工程	周期性强：窗口选择与节假日敏感；缺失会传播，建议对窗口内缺失比例设阈值	`load_roll_mean_24h`、`load_roll_max_168h`（同单位）

动态特征	数据类型	频率	可能数据源（优先官方/原始）	获取方法	质量风险与缺失处理建议	示例字段名（单位）
日历：小时/星期/月份	INT/SMALLINT	小时	本地生成；节假日来自政府公开列表	计算 + 维表 join	无缺失；注意按 HKT 计算 hour-of-week	`hour_of_day`（0-23）、`day_of_week`（1-7）、`week_of_year`
法定节假日/公众假期标记	BOOLEAN	日→小时展开	政府公众假期数据集与 GovHK 假期页面；iCal 订阅亦可	API/下载；按日表再展开到小时	节假日临时调整/补假；建议以官方源为准并记录版本	`is_public_holiday`（0/1）[11]
重要事件（演唱会/大型展会/极端事件）	CATEGORICAL + FLOAT	日/小时	事件本体常需从官方/主办方公告或权威日历抓取（“未指定”具体源）；天气警告可来自天文台	爬取/公告整理；天气警告用 API	事件数据主观性强、覆盖不全；建议先做“事件强度=0/1/人流代理”并可追溯来源	`event_type`，`event_intensity`（0-1）[2]
气温（分测站/分区聚合）	FLOAT	分钟级/小时级/日级（视接口）	香港天文台开放数据：weather.php（当前天气）、opendata.php（日/多要素接口等）以及气候资料下载页	API 拉取 + 自建归档；或下载日数据	部分数据“临时/只做有限校验”提示存在；缺失可用邻站/时间插值；记录测站与权重	`temp_c`（°C），`station_id`[12]
相对湿度	FLOAT	同上	香港天文台开放数据	API/下载 + 归档	同上；湿度对空调负荷敏感，建议保留原始与派生体感温度	`rh_pct`（%）[2]
降雨（小时）	FLOAT/STRING	小时	香港天文台 hourlyRainfall 接口：数据注明“临时、有限校验”，且可能返回“M”表示维护不可用	API 轮询归档	“M”与临时数据需转为缺失并打质量标记；可用 0/插值/邻站回填视任务	`rainfall_mm`（mm），`rainfall_raw`（STRING）[13]
UV 指数/太阳辐射或日照代理	FLOAT	小时/日	香港天文台当前天气报告含 UV；气候资料页也含日照相关下载	API/下载	城市负荷对日照/辐射（影响空调与光伏）可能相关；缺失可用季节均值	`uv_index`，`sunshine_hours`（h）[14]

动态特征	数据类型	频率	可能数据源（优先官方/原始）	获取方法	质量风险与缺失处理建议	示例字段名（单位）
天气警告/摘要（暴雨、酷热、台风等）	CATEGORICAL	小时	香港天文台 weather.php 提供 warning summary / warning info	API	警告有强事件驱动效应；建议把“警告类型 one-hot + 强度”入模；缺失=无警告	`warn_tc`、`warn_rainstorm`（0/1）[2]
旅客/人口流动：每日出入境客流（按关口、居民/访客拆分）	INT	日	入境处“每日旅客流量统计”开放数据，字段定义含：日期、管制站、入境/出境、港人/内地访客/其他访客/总数	下载 CSV/API（数据源页给出更新频率 Daily）	口岸分类变化；节假日尖峰；缺失可用同周同日回填并保留“缺失标记”	`imm_total`（人次/日），`imm_hk_resident` 等[15]
交通活动代理：干道探测器车速/车流/占有率（原始数据）	FLOAT/INT	分钟级	运输署“战略/主要道路交通数据”，原始每 1 分钟更新，提供车流、车速、占有率	API/下载 XML；建议自建归档并聚合到小时/分区	高频接口常无历史包，需要自归档；探测器故障导致异常；缺失用邻近探测器或聚合鲁棒统计	`traffic_speed_kmh`，`traffic_volume_vpm`，`road_occupancy_pct`[16]
城市交通衍生指数（分区小时活跃度）	FLOAT	小时	由运输署探测器数据聚合派生	ETL 聚合	聚合口径影响可解释性（按道路分区映射）；建议保留 detector→zone 映射与权重	`mobility_index`（0-1）
公交/运输月报类指标（客运量等，低频补充）	FLOAT/INT	月	运输署“Monthly Traffic and Transport Digest（CSV）”	下载	低频，更多用于长期趋势/结构变化，不用于短期小时预测的主驱动	`mtr_ridership_monthly`（人次/月）[17]

动态特征	数据类型	频率	可能数据源（优先官方/原始）	获取方法	质量风险与缺失处理建议	示例字段名（单位）
分区/行业用电销售（低频结构特征）	FLOAT/INT	月/季	中电公开数据页包含按客户类别的销售（GWh）、客户数、均值用电，并有月度销售分析；港灯在data.gov.hk提供半年度按区用电量与客户数	下载 CSV	低频不适合解释短期波动，但能补偿“长期趋势/结构变化”；与小时负荷需做时间插值/前向填充并标注低频来源	`sales_gwh_q`，`customers_k`，`consumption_kwh_halfyear` [8]
分区可再生能源发电量（代理：分布式光伏等）	FLOAT	月/半年度	港灯在data.gov.hk提供可再生发电量（按类型/按区/按场所类型）；中电公开页也提供可再生发电（按九龙/新界）	下载	频率较低；用于解释“净负荷（负荷-本地发电）”时更有意义；缺失前向填充	`re_gen_kwh`（kWh） [18]
电价/燃料调整费（如可得）	FLOAT	月	（未指定）需从电力公司тариф/账单规则抓取；多为月度或更低频	爬取/手工维护	口径复杂、变更频繁；对短期预测可能影响有限但对长期有用	`tariff_hkd_per_kwh`（HKD/kWh）

静态特征候选（不随时间或低频变化）

静态特征	数据类型	更新频率	可能数据源（优先官方/原始）	获取方法	质量风险与缺失处理建议	示例字段名（单位）
分区/行政边界与映射	GEOMETRY/JSON	低频	人口普查/区议会分区边界等公开资料	下载/接口	边界版本变动需版本化；分区映射（18区→三大区）需固定表	`zone_geom`（WKT/GeoJSON） [19]

静态特征	数据类型	更新频率	可能数据源（优先官方/原始）	获取方法	质量风险与缺失处理建议	示例字段名（单位）
建筑物足迹（building footprint）与建筑属性（类型/名称/高度等）	GEOMETRY + CATEGORICAL + FLOAT	月（官方标注）	地政总署 Building 数据：描述为多边形永久建筑/结构，含建筑类型、名称、高度等，更新频率 Monthly	API（CSDI）/ data.gov.hk 入口	几何拓扑错误、重叠；属性缺失；建议设定 geometry validity 校验与字段缺失率阈值	`building_height_m`（m），`footprint_area_m2`（m^2）[20]
建筑密度/楼面面积代理（分区聚合）	FLOAT	月/季	由建筑足迹聚合派生（按区/分区求总足迹面积、平均高度等）	ETL 聚合	建筑数据口径（永久建筑）与真实可用面积可能有偏差；建议与统计/抽样校准	`sum_footprint_m2`（m^2）
人口规模/密度（按区）	INT/FLOAT	年/普查/统计更新	统计处发布的区级人口/密度等表格与普查资料；统计处网页提供 API 示例以便取数	API/下载	年中/年末口径差、重基准；缺失前向填充并记录版本	`population`（人），`pop_density`（人/km^2）[21]
产业结构/用电结构（宏观）	FLOAT	年	机电工程署发布“能源最终用途数据/能耗指标”，并在 data.gov.hk 提供对应表格下载	下载	年度频率只能用于长期趋势/结构解释	`elec_share_residential`（%）[22]
电动车充电设施密度（代理新增负荷）	INT	日/不定期	环保署等部门提供“公共可用 EV 充电器”数据集（数据入口可在公开库找到）	下载/API	点位可能变动；需要去重与地理匹配；缺失=0	`ev_charger_count`（个）[23]

静态特征	数据类型	更新频率	可能数据源（优先官方/原始）	获取方法	质量风险与缺失处理建议	示例字段名（单位）
智能电表覆盖率/客户数（结构）	INT/FLOAT	月/季	中电公开信息与年报/新闻稿提及智能电表与数据能力；港灯智能电表服务说明	爬取/下载/人工维护	指标口径不统一；更适合作为“数据可得性元信息”而非模型特征	`smart_meter_penetration`（%）[24]
数据源元数据（许可/更新频率/API 端点）	JSON/TEXT	变更时	data.gov.hk Terms、各数据集字典/说明	维护表	许可条款与免责声明需保留；来源变更要可追溯	`source_url`，`license_note`[25]

推荐检索入口（便于课程组快速定位数据）

- 香港天文台开放数据与 API 文档：[26]
- GovHK 假期页 + 1823 iCal / data.gov.hk 公共假期数据集：[27]
- 入境处每日旅客流量统计（字段规范 PDF）：[15]
- 运输署道路探测器交通数据（分钟级）：[16]
- 地政总署 Building（建筑足迹）数据（data.gov.hk → CSDI API）：[28]
- 统计处能源统计/旅客统计表格（含 API）：[29]
- HKUST 校园智能电表公开数据（Dryad）：[30]

规范化关系型与时序混合数据模型

总体建模原则

1）**事实表（Fact）**承载高频时序：负荷、天气（小时或更高频）、交通（分钟→小时聚合）、客流（日→小时展开）。
2）**维表（Dim）**承载低频/静态：分区、行政区、测站、建筑、控制点（关口）、数据源与许可。
3）所有时序表都要有：`ts_utc`（TIMESTAMPTZ）作为物理主时间键，同时保留 `ts_local`（本地时间）或可由视图生成；以便严格处理时区与周聚合。香港天文台 API 示例明确使用带时区时间格式（含 +08:00）。[2]

时间对齐与时区处理规则（强制约定）

- **存储规范**：所有事实表用 `ts_utc` 存储为 UTC 的 `TIMESTAMPTZ`；同时可存一列 `ts_local`（不带时区的本地表示）用于排查。
- **对齐粒度**：训练/预测主粒度为小时：统一把时间截断到整点（floor to hour），并保证所有特征在该小时窗口内可得。
- **转换规则**：源数据若已是 HKT（+08:00），入库时转为 UTC 并保留原始时间串（可选 `raw_time_str`）。香港天文台文档对时间字段给出带时区示例，适合做解析基准。[31]

- **周聚合**：以 `ts_local` 的 ISO 周定义周编号 `iso_year_week`，并在特征层生成 `hour_of_week`（0–167）。

表结构设计（核心表 + 必选表）

下面给出一个可直接落地到 PostgreSQL/TimescaleDB 的建议（类型可按数据库调整）。为便于课程实现，字段命名采用 snake_case，主键/外键显式标注。

分区维表 dim_zone

字段	PK	FK	类型	注释
zone_id	☒		VARCHAR(32)	分区主键：`HK_TOTAL` / `KOWLOON` / `HK_ISLAND` / `NEW_TERRITORIES`
zone_name_zh			TEXT	中文名
zone_level			SMALLINT	0=全港，1=大区，2=更细（未指定）
geom			GEOMETRY	分区边界（可选，便于空间聚合）
notes			TEXT	分区口径说明（如与供电公司服务区映射） [8]

主时序负荷表 fact_load_hourly（必选）

字段	PK	FK	类型	注释
ts_utc	☒(与 zone_id 组合)		TIMESTAMPTZ	小时起始时间（UTC）
zone_id	☒(与 ts_utc 组合)	→ dim_zone.zone_id	VARCHAR(32)	分区
ts_local			TIMESTAMP	本地整点（HKT），用于审计
load_value			DOUBLE	负荷值（单位由 load_unit 指定）
load_unit			VARCHAR(8)	`kWh` / `kW` / `MW`
measure_type			VARCHAR(16)	`energy`（能量）/ `demand`（功率）
data_source_id		→ dim_data_source.data_source_id	VARCHAR(64)	数据来源（电力公司/校园/合作等）

字段	PK	FK	类型	注释
quality_flag			VARCHAR(16)	`ok` / `estimated` / `missing` / `anomaly` / `partial`
ingestion_run_id		→ dq_ingestion_run.run_id	VARCHAR(64)	本次入库批次

主负荷数据的“公开可得性”在城市层面可能受限，因此用 `data_source_id` 与 `measure_type` 把来源与度量显式化，便于课程先用公开数据替代、后续再切换到真实城市分区负荷。[32]

天气原始表 fact_weather_observation（必选）

字段	PK	FK	类型	注释
ts_utc	☒(与 station_id 组合)		TIMESTAMPTZ	观测时间（UTC）
station_id	☒(与 ts_utc 组合)	→ dim_weather_station.station_id	VARCHAR(16)	测站（按天文台代码/自定义）
ts_local			TIMESTAMP	HKT 时间
temp_c			DOUBLE	气温（°C）
rh_pct			DOUBLE	相对湿度（%）
rainfall_mm			DOUBLE	小时雨量（mm），若源返回 “M” 则置空并打标
wind_speed_ms			DOUBLE	风速（m/s，可选）
weather_warn			JSONB	天气警告/提示（可选）
data_source_id		→ dim_data_source.data_source_id	VARCHAR(64)	来源（天文台 API/下载）
quality_flag			VARCHAR(16)	`ok` / `provisional` / `maintenance_missing` 等

天文台明确提示部分降雨数据“临时、有限校验”，亦可能返回 “M” 表示维护不可用，因此建议将 `rainfall_raw` 解析前置到 staging，并在事实表用 `quality_flag` 可追溯地记录。[33]

分区天气聚合表 fact_zone_weather_hourly（推荐，便于 join）

字段	PK	FK	类型	注释
ts_utc	☒（与 zone_id 组合）		TIMESTAMPTZ	小时
zone_id	☒（与 ts_utc 组合）	→ dim_zone.zone_id	VARCHAR(32)	分区
temp_c_wavg			DOUBLE	按权重聚合的温度（°C）
rh_pct_wavg			DOUBLE	聚合湿度（%）
rainfall_mm_sum			DOUBLE	分区雨量汇总（mm）
station_count_used			SMALLINT	使用测站数量
quality_flag			VARCHAR(16)	聚合质量（如测站覆盖不足）

人口/旅客流量表 fact_people_flow_daily（必选）

字段	PK	FK	类型	注释
date_local	☒（与 control_point_id、direction 组合）		DATE	本地日期（HKT）
control_point_id	☒	→ dim_control_point.control_point_id	VARCHAR(64)	关口/管制站
direction	☒		VARCHAR(8)	`arrival` / `departure`
hk_residents			INTEGER	港人（人次/日）
mainland_visitors			INTEGER	内地访客（人次/日）
other_visitors			INTEGER	其他访客（人次/日）
total_passengers			INTEGER	总人次/日
data_source_id		→ dim_data_source.data_source_id	VARCHAR(64)	来源
quality_flag			VARCHAR(16)	质量标记

字段定义与口径可直接对齐入境处开放数据规范（日期格式、关口名、入境/出境以及三类人群拆分）。[34]

建筑物/项目静态表 dim_building（必选）

字段	PK	FK	类型	注释
building_id	☒		VARCHAR(64)	建筑唯一标识（可用官方 id 或自建 hash）
building_name			TEXT	建筑名（如有）
building_type			VARCHAR(64)	类型（住宅/商业/工业/公共等，按源提供）
height_m			DOUBLE	建筑高度（m）
footprint_geom			GEOMETRY	建筑足迹多边形
district_id		→ dim_district.district_id	VARCHAR(32)	行政区（18 区）
zone_id		→ dim_zone.zone_id	VARCHAR(32)	大区映射（港岛/九龙/新界）
source_version			VARCHAR(32)	数据源版本/更新时间
data_source_id		→ dim_data_source.data_source_id	VARCHAR(64)	地政总署/CSDI 等

地政总署 Building 数据在 data.gov.hk 的说明中明确：以多边形表示永久建筑/结构（含足迹），并包含建筑类型、名称、高度等；且标注更新频率 Monthly，适合做静态/缓变维表。[35]

节假日/事件表 dim_calendar_event（必选）

字段	PK	FK	类型	注释
date_local	☒（与 event_id 组合）		DATE	日期（HKT）
event_id	☒		VARCHAR(64)	事件/假期 id（可用 slug）
event_name			TEXT	名称
event_type			VARCHAR(32)	`public_holiday` / `school_holiday` / `mega_event` / `weather_event` 等
is_public_holiday			BOOLEAN	是否公众假期
expected_impact			DOUBLE	影响强度（0-1，人工或规则）

字段	PK	FK	类型	注释
source			VARCHAR(64)	来源（GovHK/1823/data.gov.hk/人工）
data_source_id		→ dim_data_source.data_source_id	VARCHAR(64)	数据源

公众假期可来自 data.gov.hk 的公众假期数据集或 GovHK 假期页面；iCal 订阅可作为更新机制之一。[11]

元数据/数据质量表（必选）

dim_data_source（来源维表）

字段	PK	FK	类型	注释
data_source_id	☒		VARCHAR(64)	来源 id
provider_name			TEXT	数据提供方
dataset_name			TEXT	数据集名
access_method			VARCHAR(16)	`api` / `download` / `scrape` / `manual`
endpoint_or_landing			TEXT	入口（若写 URL 建议放在配置/代码中）
update_frequency			TEXT	更新频率（原文保留）
license_note			TEXT	许可/条款摘要（遵循 data.gov.hk Terms）
owner_ipr			TEXT	知识产权声明（如数据集页标明）

data.gov.hk Terms 明确了使用条款、免责声明、以及政府/相关机构对数据更新与责任的限制，建议把关键条款摘要写入 `license_note` 并版本化。[25]

dq_ingestion_run（入库批次与质量结果）

字段	PK	FK	类型	注释
run_id	☒		VARCHAR(64)	批次 id（时间戳+hash）
run_ts_utc			TIMESTAMPTZ	执行时间
pipeline_version			VARCHAR(32)	代码/容器版本（git sha）
table_name			VARCHAR(64)	目标表
rows_in			BIGINT	输入行数
rows_loaded			BIGINT	成功入库行数
missing_rate			DOUBLE	缺失率
anomaly_rate			DOUBLE	异常率（规则定义）

字段	PK	FK	类型	注释
notes			TEXT	失败原因/修复记录

样本数据行（用于结构校验）

以下为**示例**（非真实数据），用于验证字段与 join 逻辑。

dim_zone（示例）

zone_id	zone_name_zh	zone_level	notes
HK_TOTAL	全港	0	全港汇总
KOWLOON	九龙	1	可与中电区域口径对齐（九龙）
NEW_TERRITORIES	新界	1	可与中电区域口径对齐（新界）

fact_load_hourly（示例）

ts_utc	zone_id	ts_local	load_value	load_unit	measure_type	quality_flag
2026-03-22 00:00:00+00	HK_TOTAL	2026-03-22 08:00:00	6800.5	MW	demand	ok
2026-03-22 01:00:00+00	KOWLOON	2026-03-22 09:00:00	2150.2	MW	demand	ok

fact_weather_observation（示例）

ts_utc	station_id	ts_local	temp_c	rh_pct	rainfall_mm	quality_flag
2026-03-22 00:00:00+00	HKO	2026-03-22 08:00:00	21.3	78.0	0.0	ok
2026-03-22 01:00:00+00	HKO	2026-03-22 09:00:00	22.1	74.0	1.2	provisional

fact_people_flow_daily（示例）

date_local	control_point_id	direction	hk_residents	mainland_visitors	other_visitors	total_passe
2026-03-22	LOK_MA_CHAU	arrival	82000	145000	12000	2
2026-03-22	HONG_KONG_AIRPORT	departure	56000	98000	34000	1

dim_building（示例）

building_id	building_name	building_type	height_m	district_id	zone_id
LD_BLDG_000001	示例大厦A	commercial	120.0	CW	HK_ISLAND
LD_BLDG_000002	示例住宅B	residential	45.0	SSP	KOWLOON

dim_calendar_event（示例）

date_local	event_id	event_name	event_type	is_public_holiday	expected_impact
2026-04-03	qingming_2026	清明节	public_holiday	1	0.6
2026-03-31	none	无	none	0	0.0

数据收集与 ETL 初步步骤

数据收集优先级与频率建议

P0（第一优先，先跑通训练闭环）
- 主负荷时序（小时）：先用可公开数据（如校园级）或样本区域数据建立管道；同时设计接口以便未来接入电力公司/智能电表导出。[32]
- 天气（小时/日）：用香港天文台开放数据接口；日数据可直接下载，小时数据建议“轮询归档”。[36]
- 节假日（日）：GovHK/data.gov.hk/1823 iCal 任意一种即可，建议双源比对。[37]

P1（第二优先，用于提升解释力与分区差异）
- 入境处每日客流：每日更新，直接下载 CSV，字段规范清晰；用于刻画工作日/假期/跨境活动对负荷的影响。[15]
- 运输署道路探测器交通：分钟级更新，适合作为“城市活跃度”代理；但需自建历史归档与小时聚合。[16]

P2（第三优先，结构性与长期趋势）
- 建筑足迹与属性（地政总署）：月更，支撑分区的建筑密度/高度/类型结构特征。[35]
- 能源结构/行业用电（机电工程署/统计处）：年更，适合长期解释与校准。[38]
- 电力公司公开低频统计（销售/客户数/分区汇总）：用于长周期趋势或结构变化修正。[8]

推荐工具栈（课程可落地）

- 采集与清洗：Python（requests、pandas、pyarrow、lxml/bs4、pydantic 或 pandera 做 schema 校验、great_expectations 做数据质量）。
- 存储：PostgreSQL + TimescaleDB（或 PostgreSQL 分区表）存事实表；对象存储/本地用 Parquet 分区（按 `table=.../dt=YYYY-MM-DD/`）做原始落地。
- 调度：Prefect/Dagster（课程易用）或 Airflow（工程化更强）。
- 版本与可复现：git + 数据快照（dataset_version、run_id）+ 依赖锁定（conda/poetry）+ 容器（Docker）。

关键 ETL 步骤明细（可直接照做）

步骤：数据接入（Extract）

1）天气（香港天文台）
- **实时/近实时**：调用 `weather.php`（当前天气、警告、9 天预报等）。[2]
- **历史/批量**：调用 `opendata.php` 拉取日/多要素 CSV/JSON；或使用“Daily Data Download”页面批量下载站点日值。[39]
- **必须自建归档**：若需要“过去 N 年的逐小时天气”，建议定时轮询（例如每 10 分钟抓一次）并写入 `fact_weather_observation`，再聚合到小时；因为部分接口更偏“当前”。[2]

2）节假日
- 从 GovHK 获取年度假期列表；并用 data.gov.hk 的公众假期数据集或 1823 iCal 做交叉校验与自动更新。 37

3）客流（入境处）
- 直接下载 CSV；字段规范明确、更新频率 Daily。 15

4）交通（运输署）
- 原始数据每 1 分钟更新，建议只抓取“已选探测器子集”或定期抓全量后聚合，避免数据量失控。 16

5）建筑静态（地政总署）
- 通过 CSDI API / data.gov.hk 入口拉取 Building 多边形与属性；月更即可。 28

步骤：落地（Load / Raw zone）

- 采用 **staging 原始区**：`stg_*` 表或 Parquet（保留原字段、原时间格式、原缺失符号如 “M”）。香港天文台降雨接口明确可能出现 “M” 和临时数据校验不足，因此 staging 必须保留 raw 字段便于追溯。 13
- 每次采集写 `dq_ingestion_run`，记录：行数、缺失率、异常率、源版本/更新时间。 25

步骤：清洗与标准化（Transform）

1）时间处理
- 统一解析源时间为 `ts_local`（HKT），再转换为 `ts_utc`；对齐到整点。香港天文台文档给出带时区时间示例，可据此做解析测试集。 31

2）缺失值
- 天气：测站缺失 → 邻站插值/分区加权时自动降权；降雨 “M” → 置空 + `quality_flag=maintenance_missing`。 13
- 负荷：短缺口（1–3 小时）可线性插值；长缺口用“同周同小时均值”或“最近 4 周同 hour-of-week 的中位数”，并把 `quality_flag=estimated`。
- 客流：缺失可同星期均值回填，并新增 `is_imputed` 标记（可放在质量字段或派生表）。 40

3）异常值
- 负荷：用 robust z-score / Hampel filter 标记尖峰；保留原值与 winsorized 值两列，避免误删真实峰值。
- 交通：探测器故障常导致 `speed=0`、`volume=0` 长时间；可用 detector-level 规则（连续 30 分钟全 0）标记 `anomaly`。 16

步骤：特征工程（Feature Layer）

建议在“模型特征视图/特征表”中固化可复用特征：
- 滞后：`lag_1h, lag_2h, lag_24h, lag_168h`（周季节）；
- 滚动：24h/72h/168h 的 mean/max/min/std；
- 日历编码：`hour_of_week` +（可选）Fourier（sin/cos）以表达周期；
- 类别编码：天气警告、事件类型做 one-hot；
- 归一化：对不同分区的负荷建议做 **per-zone 标准化** 或使用比例特征（如 `load / rolling_mean_168h`），以减弱规模差异；
- 聚合策略：对交通/客流这种非小时数据，建立“日→小时展开”的规则（例如把当日总客流分配到工作时段权重，或仅作为日级特征并在小时上前向填充）。 41

建议的数据管道流程图（Mermaid）

```
flowchart LR
  A[源数据 API/下载/爬取] --> B[staging 原始落地 stg_* / Parquet]
  B --> C[清洗标准化: 时间/缺失/异常]
  C --> D[维表: 分区/测站/建筑/关口映射]
  C --> E[事实表: load_hourly/weather_obs/people_flow/traffic_agg]
  D --> F[特征层: lag/rolling/calendar/zone_weather]
  E --> F
  F --> G[训练/评估/回测: week-ahead 168h]
  G --> H[预测输出: zone-week load curve + 聚合指标]
  C --> I[质量与元数据: dq_ingestion_run]
  E --> I
```

课程组里程碑与时间线（Mermaid 甘特图）

```
gantt
  title Hong Kong Weekly Load Curve Dataset - Course Timeline
  dateFormat  YYYY-MM-DD
  section P0 最小可用数据集
  Schema设计与字段字典          :a1, 2026-03-30, 7d
  天气+节假日ETL跑通           :a2, after a1, 7d
  主负荷数据接入(先用公开替代)  :a3, after a2, 7d
  特征工程+基线模型             :a4, after a3, 7d
  section P1 扩展特征
  入境客流ETL+对齐             :b1, after a4, 7d
  交通探测器ETL(聚合到小时/分区) :b2, after b1, 7d
  section P2 静态结构与工程化
  建筑足迹与分区聚合特征        :c1, after b2, 7d
  数据质量规则+版本化发布        :c2, after c1, 7d
```

课程项目简化基线数据集与 HKUST 数据集整合评估

简化基线数据集版本（小规模、可公开获取）

为确保“可复现 + 可公开分享”，建议课程项目先构建如下最小闭环：

- **负荷（小时）**：采用 香港科技大学（HKUST）[42] 校园智能电表公开数据（Dryad），该数据集介绍为覆盖超过 1,400 个电表、20+ 建筑、约 2.5 年，并可用于负荷预测等任务。[30]
- **天气（日/小时代理）**：采用香港天文台开放数据：
- 日值：通过 `opendata.php` 或 climate download 页面下载（温度/湿度/降雨等）。[43]
- 若要小时级：定时轮询 `weather.php?dataType=rhrread` 并归档。[2]
- **日历**：公众假期（GovHK / data.gov.hk / 1823 iCal）。[37]
- **可选扩展**：入境处每日旅客流量（P1）、运输署分钟级交通（P1），作为城市活动代理，帮助解释周末/节假日负荷差异。[41]

课程组已在项目提案中明确以 HKUST 校园智能电表数据与香港天文台天气数据作为主要数据源，并以小时级用电作为预测目标，这与上述“先跑通基线闭环”的策略一致。
⌧filecite⌧turn0file0⌧

如何用 HKUST 数据集评估“单栋/建筑群耗电量整合方法”

HKUST 数据集的典型结构是“电表→空间/设备→建筑”的层级（论文描述其采用 Brick Schema 等策略进行整理）。[44] 课程中可用如下方法评估“整合（aggregation）”的合理性与对预测的影响：

1）**定义整合层级与目标**
- 单栋预测：`building_load_hourly = sum(meter_kwh_hourly)`（同一栋内所有相关电表求和）。
- 建筑群预测：按“功能/区域/楼群”对多栋求和，形成“cluster_load_hourly”。

2）**整合质量评估（不依赖外部真值的可操作指标）**
- 覆盖率：某栋建筑在某小时参与求和的电表数量占“该栋应有电表数”的比例（用 `active_meter_count/expected_meter_count`）。
- 不一致性：若同一栋存在“总表 + 分表”，可检查 `abs(total_meter - sum(sub_meters))` 的统计分布（需元数据标注）。
- 缺测传播：对比“插值前后/过滤前后”的峰值保留率与周曲线形态差异（如 DTW 距离或简单的峰谷时刻偏移）。

3）**对预测性能的影响评估（面向课程模型）**
- 用同一模型族（线性回归/树模型/集成模型等）分别训练：
- “电表级建模 → 预测后再求和”（bottom-up forecast）
- “先求和成建筑/建筑群 → 直接预测”（top-down / aggregate-first）
- 对比两种策略在**周曲线**上的误差：
- 点误差（RMSE/MAE）按 168 小时平均；
- 形状误差（对预测曲线做标准化后再算 RMSE 或 DTW）；
- 峰值指标误差：峰值大小、峰值出现小时。

4）**与“香港整体/分区”整合方法的对接**
- 将“建筑群”视为“分区负荷”的微型代理：例如按楼群位置映射到“港岛/九龙/新界”之一，再做 `zone_proxy_load = sum(cluster_load)`；用以验证“分区映射 + 聚合 + 周曲线预测”的全链路是否工作。
- 未来若获得真实分区负荷（来自电力公司或合作），只需替换 `fact_load_hourly` 的 `data_source_id` 与 `zone_id` 数据装载，特征与管道基本不变。[10]

后续补充与维护流程与路线图

增量更新策略

1）**append-only**：事实表按时间追加，不做“原地覆盖”；若源数据修订则以 `quality_flag` + 新版本记录覆盖逻辑视图（例如 `fact_load_hourly_latest`）。
2）**分区式数据湖**：原始与清洗后数据分别以 Parquet 分区保存（按日期/表名/来源），并在 `dim_data_source` 与 `dq_ingestion_run` 记录每次运行的输入快照。
3）**高频源自建历史**：对分钟级交通、当前天气等接口，优先“定时抓取并归档”，因为公开站点往往不保证历史包持续可用；同时 data.gov.hk Terms 明确政府不承担持续更新义务并可随时修订/暂停提供数据，工程上必须预留“断流处理”。[45]

数据验证与质量门禁（Data Quality Gates）

建议为每个事实表建立“硬规则 + 软规则”：

- 硬规则（入库即失败）：
- 主键重复（同 `zone_id, ts_utc` 出现多行）；
- `ts_utc` 非整点（小时表）；
- 单位缺失或不在白名单（kWh/kW/MW）。
- 软规则（入库但标记）：
- 缺失率超过阈值（如 >5%）；
- 峰值突变超过分位数阈值（如超过 P99.9 且持续 1 小时）；
- 天气降雨出现 “M” 等维护缺失（按天文台文档提示处理）。 [33]

版本控制与可复现管道

- **代码版本**：每次训练/数据生成记录 git commit（写入 `dq_ingestion_run.pipeline_version`）。
- **数据版本**：对外发布时提供 `dataset_version`（日期+hash），并保留“数据字典 + 来源列表 + 许可摘要”。data.gov.hk Terms 对使用条件与免责声明有明确约束，应在发布包中保留引用与摘要。 [25]
- **可复现运行**：建议将所有 API 端点、密钥、轮询频率写入可审计配置（YAML），并在运行日志中固化。香港天文台 API 端点在文档中明确给出（如 weather.php、opendata.php、hourlyRainfall.php）。 [31]

隐私与合规注意事项（尤其是细粒度用电）

- **PDPO 边界**：香港《个人资料（私隐）条例》（PDPO）对个人资料的处理、保存期限、准确性等有要求；PCPD 的概览材料强调需采取可行步骤保障准确性与不超期保留，并涉及删除义务。 [46]
- **智能电表/住户级数据的敏感性**：即使不直接包含姓名，细粒度用电曲线也可能在特定场景下具备可识别性（活动模式推断）。因此建议：
- 最小化采集：只采集模型必要字段；
- 去标识化：用不可逆 hash 作为 meter/building 标识；
- 聚合发布：对外只发布分区/建筑群聚合，不发布单住户；
- 访问控制：把原始细粒度数据放在受限库，只有派生聚合层可共享。 [47]

扩展到更细粒度（楼宇/用电端）的路线图

1）**从分区到 18 区/网格**（中期）：
- 利用区界/普查资料与建筑足迹，把负荷、交通、客流在空间上做更细映射；分区维表扩展 `zone_level=2`。 [48]

2）**从城市级到楼宇级**（中期）：
- 接入更多公开楼宇能耗数据源（若无，则通过合作/校园/园区项目）；建立 `dim_meter` 与 `bridge_meter_building` 映射表，支持多表计、多用途建筑。 [49]

3）**从楼宇到终端（HVAC/照明/插座）**（长期）：
- 需要更丰富的设备级计量与元数据标准（如 Brick Schema）；模型上可从整体负荷预测扩展到分项负荷与需求响应场景。 [50]

4）**与电力公司开放数据的衔接**（机会型）：
- 中电与港灯已有一定公开统计与可再生发电数据；同时服务说明显示对客户侧提供小时/半小时用电数据查看与下载能力，这意味着“在合规与授权下”存在建立更广泛样本数据集的可能，但需要明确授权、脱敏与数据共享协议。 [51]

1 2 12 13 14 31 33 36 39 hko.gov.hk
https://www.hko.gov.hk/en/weatherAPI/doc/files/HKO_Open_Data_API_Documentation.pdf

3 9 10 Smart Energy Online
https://www.clp.com.hk/en/business/low-carbon-solutions/energy-management/smart-energy-online

4 30 32 49 Data: A 2.5-year campus-level smart meter database with ...
https://datadryad.org/dataset/doi%3A10.5061/dryad.k3j9kd5h6?utm_source=chatgpt.com

5 46 47 The Personal Data (Privacy) Ordinance
https://www.pcpd.org.hk/english/data_privacy_law/ordinance_at_a_Glance/ordinance.html?utm_source=chatgpt.com

6 16 45 Traffic Data of Strategic / Major Roads | DATA.GOV.HK
https://data.gov.hk/en-data/dataset/hk-td-sm_4-traffic-data-strategic-major-roads

7 34 40 Data Specification for Statistics on Daily Passenger Traffic
https://www.immd.gov.hk/opendata/eng/transport/immigration_clearance/data_specification_for_statistics_on_daily_passenger_traffic.pdf

8 51 CLP Open Data
https://www.clp.com.hk/en/media-resources/clp-open-data

11 42 Hong Kong Public Holidays Data
https://data.gov.hk/en-data/dataset/hk-dpo-statistic-cal?utm_source=chatgpt.com

15 41 Statistics on Daily Passenger Traffic | DATA.GOV.HK
https://data.gov.hk/en-data/dataset/hk-immd-set5-statistics-daily-passenger-traffic

17 Monthly Traffic and Transport Digest (CSV)
https://data.gov.hk/en-data/dataset/hk-td-tis_17-monthly-traffic-and-transport-digest-csv?utm_source=chatgpt.com

18 Renewable Energy Generation Amount (kWh) by ...
https://data.gov.hk/en-data/dataset/hkelectric-cs_cbd-renewable-energy-generation-by-renewable-energy-type?utm_source=chatgpt.com

19 48 2021 Population Census (Statistics and Boundaries of ...
https://data.gov.hk/en-data/dataset/hk-censtatd-census_geo-2021-population-census-by-dcd?utm_source=chatgpt.com

20 28 35 Building - Building | DATA.GOV.HK
https://data.gov.hk/en-data/dataset/hk-landsd-openmap-landsd-building/resource/e62b1e3f-c766-408f-a104-7848a775cbba

21 Census and Statistics Department
https://www.censtatd.gov.hk/?utm_source=chatgpt.com

22 38 Hong Kong Energy End-use Data (305)
https://www.emsd.gov.hk/en/energy_efficiency/energy_end_use_data_and_consumption_indicators/hong_kong_energy_end_use_data/index.html?utm_source=chatgpt.com

23 Electric Vehicle Chargers for Public Access in Hong Kong
https://opendata.esrichina.hk/datasets/electric-vehicle-chargers-for-public-access-in-hong-kong-1/about?utm_source=chatgpt.com

24 Smart Meters
https://www.clp.com.hk/en/residential/smart-meters?utm_source=chatgpt.com

25 Terms and Conditions | DATA.GOV. ...
https://data.gov.hk/en/terms-and-conditions?utm_source=chatgpt.com

26 Hong Kong Observatory Open Data
https://www.hko.gov.hk/en/abouthko/opendata_intro.htm?utm_source=chatgpt.com

27 37 General holidays for 2022 – 2026
https://www.gov.hk/en/about/abouthk/holiday/?utm_source=chatgpt.com

29 Table 915-91204 : Generating capacity and peak demand ...
https://data.gov.hk/en-data/dataset/hk-censtatd-tablechart-915-91204/resource/94a3ddbe-4069-4250-a2bc-ff651b235403?utm_source=chatgpt.com

43 Daily Data Download
https://www.hko.gov.hk/en/cis/downloadpage.htm?utm_source=chatgpt.com

44 A multi-year campus-level smart meter database
https://www.nature.com/articles/s41597-024-04106-1?utm_source=chatgpt.com

50 Metadata schema for portable smart building applications
https://brickschema.org/papers/Brick-AppliedEnergy-2018-Balaji.pdf?utm_source=chatgpt.com